基于深度强化学习的多时间尺度电力交易策略研究

课程设计报告

> ## ⚠ 结论撤回说明（2026-10-21）
>
> 外部复核发现：迭代 7 及之前的结算实现把同一度电在"合同成本"与"现货成本"两个口径里重复计量
> （约 3.25 倍，已在 `experiments/test_settlement_accounting.py` 中定量复现），因此本报告原先给出的
> 年成本绝对值与全部改进百分比已整体作废，并从正文、表格与图链中删除，不能作为成果引用；
> 撤回的原始数值只能在 git 历史（提交 `f2b4f7c` 及之前）中查见。第 5 章改为只陈述
> 作废的理由与口径修正后的可复现实测，不再罗列任何旧口径数字。
>
> 迭代 8 完成了四类修复：① 逐交割月合同台账与偏差结算（会计）；② 设备执行闭环（EV SOC 时序积分、
> 工业日任务守恒，删除"调整后负荷重新归一化"）；③ 信息边界（发布游标，观察不含未来实现值）；
> ④ 双智能体按角色决策时序（半 MDP，跨步折扣 γ^Δt）与模型重载一致。配套 43 个验收用例全部通过，
> 并建立四臂配对世界基准（固定比例 + 保障调度 / 滚动规则 + 预测调度 / 上层 SAC + 规则下层 / 双 SAC）。
>
> 当前可主张：建模与实现自洽、账目可手算、物理闭环可复算、实验框架公平（含非学习强基线）。
> 当前不可主张：任何 DRL 相对基准的降本比例。正式性能结论以重训结果
> `results/four_arm_benchmark.json`（进行中）为准。
>
> 最低验收门槛（已逐项通过）：无虚假退款、电量守恒、设备按时完成、费用可手算、
> 观察不含未来实现值、模型重载一致。

摘要

在电力市场化改革不断深入的背景下，售电公司和大用户需要在年度、月度、月内（日前）与现货等多个时间尺度市场上协同决策购电仓位，并利用电动汽车（EV）集群与工业可转移负荷等柔性资源参与需求响应，以实现购电成本的最小化。该问题具有多时间尺度耦合、序贯决策、动态环境三大特征，传统优化方法难以同时刻画"当前决策影响未来状态"的时序依赖关系。

本文将上述问题建模为多时间尺度马尔可夫决策过程（**MDP**），提出一种双深度强化学习（**DRL**）智能体协同框架：中长期智能体（SAC）决策年度/月度/月内三级合同的逐交割月覆盖率 α/β_m/γ_m，柔性调度智能体（SAC）决策当月柔性调度强度（它只决定"多大程度择优用电/放电"，不决定现货采购电量——现货侧只结算合同量与实际净需求之差），二者通过仓位约束与信息衔接相互耦合，严格满足任务书"针对不同交易时间尺度构建相互衔接的深度强化学习智能体"的要求。

针对多智能体强化学习在该场景下的信用分配（**credit assignment**）难题——中长期决策主导绝大部分成本、现货柔性调节只影响较小的边际成本——本文提出未来暴露成本塑形（**future-exposure reward shaping**）机制：在中长期智能体的月内决策步，将其 γ_m 决策所引致的现货敞口成本显式计入即时奖励，使智能体"感知"少锁仓→高现货暴露→未来高成本的因果链。开发阶段的消融实验显示该机制是解决信用分配的关键承重部件，而奖励放大与三阶段交替训练并无稳定收益，据此将方案简化；该消融结论测量于作废的结算口径之上，需在新口径下重做（见第 5 章）。

本文完成了从市场建模、柔性负荷物理执行、双 DRL 智能体到四臂配对世界基准的全链路实现与可复算验证（43 个验收用例覆盖"无虚假退款、电量守恒、设备按时完成、费用可手算、观察不含未来实现值、模型重载一致"）。性能方面，本文只给出已复核的非学习基线标定（滚动规则相对固定比例的改进为 +0.1%~+2.2%，视场景而定），并据一次同配置重复运行测得的运行间噪声（0.09%~0.37%）设定判读门槛：改进需明显大于 0.4% 且在 3 个种子 × 10 个配对世界上方向一致，才作为证据写入结论。双 DRL 方案相对基线的实际改进幅度尚待按修正后的会计口径重训得出，本报告不在结论未产生时宣称具体降本比例。

关键词：深度强化学习；软演员-评论家（SAC）；多时间尺度电力交易；柔性负荷；信用分配；奖励塑形；CVaR

第 1 章 引言

1.1 研究背景与意义

随着电力体制改革推进，我国逐步建立起"中长期交易 + 现货交易"相互衔接的多层次电力市场体系。售电公司与大工业用户面临的核心经营问题是：如何在时间跨度、价格机制、风险特征各不相同的多级市场中安排购电组合，并借助需求侧柔性资源优化用能曲线，最终实现总购电成本最小化。

- 多时间尺度：年度双边协商、月度集中竞价、月内（日前）滚动、现货（日内/实时）市场在提前期、流动性和价格水平上差异显著。年度合同通常价格较低但锁定量大、灵活性差；现货市场价格波动剧烈、存在尖峰风险，但提供了低负荷时段的机会。
- 序贯性与耦合性：前期锁定的仓位约束了后期的可选决策空间（$0 \le \alpha \le \beta \le \gamma \le 1$），当前月的现货暴露由累计中长期仓位决定，决策之间存在跨期耦合。
- 柔性资源协同：EV 集群充放电与工业可转移负荷可在时间上平移用电，是平抑现货尖峰、降低暴露成本的重要抓手。

传统随机规划/鲁棒优化方法虽能处理不确定性，但需要对价格分布做较强假设，且在高维状态空间中求解代价大、难以刻画长时序依赖。深度强化学习（DRL）能够通过与环境交互端到端地学习序贯策

略，天然适合此类多阶段动态决策问题，因此本文采用 DRL 求解多时间尺度电力交易策略。

1.2 国内外研究现状

（1）电力市场交易决策优化。 早期研究以混合整数规划、随机规划刻画中长期合约组合，通过场景生成与削减处理价格不确定性；近年来鲁棒优化、条件风险价值（CVaR）被广泛用于控制现货暴露带来的尾部风险。此类方法的共同局限在于：最优策略高度依赖对未来价格分布的准确假设，且模型规模随时间尺度与决策维度迅速膨胀。

（2）**DRL** 在能源交易中的应用。 深度 Q 网络（DQN）、近端策略优化（PPO）、软演员-评论家（SAC）等算法已被用于电池储能套利、需求响应调度、电力竞价等任务。相较 DQN 仅适用于离散动作，SAC 在连续动作空间中兼具最大熵探索、样本效率与训练稳定性，适合输出连续的交易比例与柔性调节量。

（3）多智能体与分层强化学习。 当决策涉及多个耦合主体时，多智能体强化学习（MARL）与分层强化学习（HRL）是主流范式。然而 MARL 面临非平稳性与信用分配两大挑战：当不同子决策对全局回报的贡献量级悬殊时，弱贡献智能体难以从噪声中学习。本文的核心技术贡献正是针对电力交易场景中"中长期合同主导成本、柔性调度只影响边际成本"这一具体挑战，提出简洁有效的奖励塑形解决方案。

1.3 本文主要工作

1. 多时间尺度市场与柔性负荷建模：构建年度/月度/月内/现货四级市场的 Gym 环境，按交割月记账（参考交付电量 R_m、合同台账、偏差结算），并集成 EV 集群与工业可转移负荷的物理执行模型（SOC 时序积分、日任务守恒）。
2. 双 **DRL** 智能体协同框架：设计中长期 SAC 智能体与柔性调度 SAC 智能体，通过动作解耦、独立经验池、按各自决策时序衔接的半 MDP 训练与仓位约束实现"相互衔接"，严格满足任务书要求。
3. 信用分配解决方案：提出未来暴露成本塑形机制，并以消融实验考察各设计部件的贡献，据此确定简化方案（消融结论需在修正会计口径下重做）。
4. 可复算的验证体系与四臂基准：43 个验收用例覆盖"无虚假退款、电量守恒、设备按时完成、费用可手算、观察不含未来实现值、模型重载一致"；建立固定比例 / 滚动规则 / 上层 SAC + 规则下层 / 双 SAC 四臂配对世界基准（同世界、同设备任务、冻结预算与种子），使任何 DRL 增益必须在够强的非学习基线前接受检验。

1.4 报告组织结构

第 2 章建立多时间尺度电力交易市场模型；第 3 章建立柔性负荷模型；第 4 章详述双 DRL 智能体方法与信用分配机制；第 5 章给出实验设置、结果与分析；第 6 章总结全文并展望未来工作。

第 2 章 多时间尺度电力交易市场建模

2.1 四级市场与逐交割月覆盖率模型

设用户在一个决策周期（本文取一年，划分为 12 个月）内的总需求电量为 Q（本文取 Q=1000 MWh，作为归一化基准），第 m 个交割月的参考交付电量为 R_m，满足

> $\Sigma_{m=1}^{12} R_m = Q$ (默认均匀 $R_m = Q/12$)

电力交易在四个时间尺度市场依次进行：

市场	提前期	符号	含义
年度市场	年	α	年度合同对每个交割月的覆盖率（全年一次签约）
月度市场	月	β_m	第 m 月在年度合同之上的累计覆盖率
月内市场	日/时段	γ_m	第 m 月中长期累计覆盖率
现货市场	实时	—	只结算合同量与实际净需求之差 A_m-γ_m R_m

每批合同的成交电量按交割月记账，增量形式保证全年合同电量恒等于 Q：

> $Q^{Y}_m = \alpha R_m$, $Q^{M}_m = (\beta_m-\alpha) R_m$, $Q^{I}_m = (\gamma_m-\beta_m) R_m$, $Q^{S}_m = A_m-\gamma_m R_m$

其中 A_m 是柔性设备实际执行后第 m 月的网侧净需求（不执行调度时 A_m=R_m）。
仓位需满足同月层内单调性：

> $0 \le \alpha \le \beta_m \le \gamma_m \le 1,\ m=1,\dots,12$

该约束是"多时间尺度衔接"的数学体现：年度决策决定该月月度决策的下界，月度决定月内的下界，而 γ_m 决定该月的现货暴露。注意单调性只在同一交割月内成立——不同月份的覆盖率可以更低，因为那是对不同交割月的独立签约，不构成对上月合同的撤销。

2.2 结算模型与合同台账

结算引擎 `SettlementEngine` 按交割月记账，每一批合同都是一条可手算复核的台账记录（`contract_id / stage / signed_step / deliver_month / quantity / price / cost`）：

- 年度：m=1..12 各记 $cost^{Y}_m = p_{annual} \cdot \alpha R_m$，全年只成交一次。
- 月度（第 m 月）：$cost^{M}_m = p^{monthly}_m \cdot (\beta_m-\alpha) R_m$。
- 月内（第 m 月）：$cost^{I}_m = p^{intraday}_m \cdot (\gamma_m-\beta_m) R_m$。
- 现货（偏差）：设该月设备执行后的逐时段网侧电量为 q^{need}_h，$A_m=\Sigma_h q^{need}_h$，把月总偏差按逐时段用量比例分摊（不做任何重归一化）：

> Δ E_h = q^need_hBig(1-(γ_m R_m)/(A_m)Big), cost^S_m=Σ_h p^spot_m,hmax(Δ E_h,0) +(1-d)Σ_h p^spot_m,hmin(Δ E_h,0)

即缺口（**Δ E_h>0**）按该时段现货价 **1:1** 买入（现货是残余市场，不再叠加惩罚项），
过购（**Δ E_h<0**）按现货价 **×(1-d)** 回售（d=sell_discount=0.20 代表批零价差，
是全文唯一显式的不对称结算参数）。

年总成本 = 四级市场成本之和 + 工业负荷转移惩罚。

> 建模说明（合同不可撤销，负增量不是"退款"）：开发过程中曾采用"跨月累计比例 + 允许负增量"的语义，
> 并声称"强制增量非负会导致成本模型膨胀约 4 倍，因此必须允许负增量"。该说法已撤回：
> 成本膨胀是因为旧口径同时把合同量与全额现货量计入成本（同一度电重复计量约 3.25 倍），
> 而不是负增量语义本身必要；任务书也明确不允许推翻已签合同。
> 最终方案改为逐交割月覆盖率：单调性 α≤β_m≤γ_m 由断言保证（不是把负增量裁成 0），
> 跨月覆盖率可以下降但不冲销上月合同；富余电量只能通过现货侧回售变现，并承受折价。
> 这样，"合同不可撤销"与"电量守恒"同时成立，成本口径可用台账逐批手算复核
> （`experiments/test_settlement_accounting.py`、
> `test_environment_accounting.py`）。

2.3 价格场景生成

为覆盖典型市场形态，构造 5 类价格场景（价格单位：元/MWh，参考我国电力现货市场水平）。月度、月内价格在基准附近叠加小幅高斯扰动；现货价格按 24 时段生成，高峰时段（9–12、18–21 时）价格上浮、低谷时段（0–6 时）下调，并叠加场景标准差以刻画尖峰风险。

场景	年度	月度	月内	现货均值	现货标准差	预期合理策略
A 年度低价后期上涨	300	350	380	420	50	倾向提高 α（多锁年度低价）
B 年度高价后期下降	420	360	330	300	40	倾向降低 α（少锁高价、多暴露低价现货）
C 各阶段价格接近	350	355	360	365	30	价格差异小，风险约束主导配置
D 现货高波动	340	350	360	400	120	倾向提高 γ（降低现货暴露以避险）
E 月度低价现货极端风险	380	310	350	500	200	在月度低价机会与现货尖峰风险间权衡

场景由 `PriceScenarioGenerator` 以固定随机种子生成，保证实验可复现。

第 3 章 柔性负荷建模

柔性资源是现货阶段降低暴露成本的关键。本文集成两类典型资源：电动汽车集群（可充可放，V2G）与工业可转移负荷（负荷时移）。关键在于：柔性动作不只是给出功率包络，而是真正推进设备物理状态，再取执行后的网侧净负荷进入市场结算。执行层为 `src/load/flexible_executor.py`。

3.1 电动汽车集群模型

`EVLoadModel` + `FlexibleExecutor` 以集群聚合方式刻画 EV 的充放电能力，主要参数：

参数	取值	说明
车辆数	50（默认）	集群规模
单车电池容量	60 kWh	—
充电功率	7 kW	上限
放电功率	3 kW	上限
SOC 范围	[0.2, 0.9]	目标 0.8，到达初始 0.3
充电/放电效率	0.90 / 0.88	网侧↔电池，往返损耗约 12.4%
到达/离开时刻	18 时 / 8 时	按在站车辆比例折算可用功率

执行层按小时积分 **SOC**（而非只检查包络），并施加如下硬约束：

- 离站前必须充回目标 SOC：soc_depart≥ target；
- V2G 放电量同时受"当前可放电量"与"离站前还能充回多少"双重限制（闭式上限），并计入往返损耗；
- 同一小时不同时充电又放电；网侧净负荷逐小时不为负。

因此"设备按时完成"是构造性保证，不是靠奖励惩罚换来的优化结果——这也是验收用例的写法。

3.2 工业可转移负荷模型

`IndustrialLoadModel` + `FlexibleExecutor` 刻画可在时间上平移的工业负荷，主要参数：

参数	取值	说明
总功率	200 kW	默认场景

可转移比例	0.3	可平移部分
转移窗口	4 h	负荷可移动的时域跨度
转移惩罚成本	50 元/MWh	产能损失的等效成本
最低生产负荷率	0.6	刚性部分，不可移动

每小时负荷拆为刚性部分 + 可转移部分：可转移部分只改变时刻分布，日任务电量严格守恒；
增载落点必须在转移窗口内且不超过可转移功率上限；若某次调整会使任务超窗不可行，则
commit-or-rollback 直接回退整笔调整。转移惩罚按实际迁移电量计入总成本。

3.3 从动作到真实网侧电量

执行顺序严格为：合法观察 → 智能体动作 → 设备实际执行 → 真实网侧电量 → 市场结算。
柔性强度 u_m ∈ [-1,1] 只决定"多大程度择优"（正号增载/充电、负号减载/放电），
逐时段落点由执行层按已公布的日前价格与上述物理约束决定。

需求形状完全由执行层给出，不再对调整后的负荷做重新归一化：物理量级只在"中性剖面"
（强度恒为 0，即保障调度）上一次性标定，使 Σ_m R_m = Q；标定系数在动作之后不再改变。
由此产生的缺口与富余如何处理，全部写成显式结算规则（见 2.2 节），不隐含在任何数组缩放里。

3.4 负荷场景组合

`LoadScenarioBuilder` 将 EV 与工业负荷组合为 5 种柔性充裕度场景，用于考察柔性规模对策略与收益的影响：

负荷场景	EV 数量	EV 充电功率	工业总功率	可转移比例
柔性充裕	100	10 kW	200 kW	0.5
柔性适中	50	7 kW	200 kW	0.3
柔性受限	20	7 kW	200 kW	0.15
纯刚性	0	—	200 kW	0.0
柔性大规模	300	7 kW	600 kW	0.5

在双 DRL 方案中，柔性调度强度由柔性调度智能体给出；作为对照，分层臂与规则臂使用
`src/agent/rule_policies.py` 中的预测调度规则（滚动比价 + 价差强度），
其放电触发门槛取物理量而非人为超参：门槛=往返损耗+过购折卖折价≈0.46。
旧的"基于价格百分位的固定削峰填谷"`FlexibleDispatcher` 只保留在历史脚本里，已不用于正式对比。

第 4 章 双 DRL 智能体方法与信用分配

4.1 问题建模为多时间尺度 MDP

将一年交易过程建模为 MDP ⟨ S, A, P, R, γ⟩。一个 episode 内，环境按"年度 → (月度 → 月内 → 现货) × 12"的顺序推进，共 37 个决策步 (1 步年度 + 12×3 步月度/月内/现货) 。

状态空间 (**13** 维，全部取自发布游标内的已公开信息) ：

> s = [α,β,γ, p_a,p_m,p_i, p̄_s,σ_s, sin t,cos t, 1-γ, c_ev,c_ind]

价格类特征按 /1000 归一化，容量按 Q 归一化。信息边界是建模的一部分：

- 年度报价在签约时点公布；某月的月度/月内报价从该月对应决策时点起可见 (价格槽位语义 = "该市场最近一次已公布的报价"，0 表示尚未开市) ；
- 某月的日前现货剖面只在该月现货决策时点可见，交割后才进入公开历史；
- 中长期阶段的 p̄_s,σ_s 使用已交割月份日前价的滚动统计 (首月无历史时退回公开年度合同价、波幅取 0) ，不再暴露"本月现货实现均值/标准差"；
- 生成器的隐含分布参数 (如场景现货均价) 已从奖励中删除，因为它不属于可观察信息。

验收：`experiments/test_information_boundary.py`——篡改未来 11 个月实现价格后，首月 4 个决策的
观察与奖励逐位不变；把生成器隐参污染成 10 亦不改变结果。

动作空间 (**2** 维) ：a=[a_ratio, a_flex]。a_ratio 由中长期智能体在中长期阶段输出，经 target=lo+σ(a_ratio)·(hi-lo) 映射为该层目标覆盖率
(hi 取年度 0.90 / 月内 1.00，lo 为已有下界) ；a_flex∈[-1,1] 由柔性调度智能体在现货阶段输出，决定调度方向与强度。每步仅由"当前阶段所属"的智能体输出有效动作，另一维填 0，实现动作解耦。

4.2 SAC 算法

软演员-评论家 (SAC) 是面向连续动作空间的最大熵离策强化学习算法，同时优化策略 π 与双 Q 价值函数，其目标含熵正则项以鼓励探索、提升鲁棒性。本文 SAC 实现要点：

- **Actor (GaussianPolicy)** ：2 层全连接 (隐藏维 256，ReLU) ，输出高斯分布的均值与对数标准差，经 tanh 压缩至 [-1,1] 并做 Jacobian 修正得到对数概率；重参数化技巧采样。
- **Critic (QNetwork，Twin)** ：双 Q 网络取较小值以抑制过估计。
- 自动温度调节：α_temp 自适应，目标熵 =-dim(A)。保存/加载时用 `log_alpha.copy_()` 原地写入，保证温度优化器的参数绑定不失效 (否则重载后 α_temp 永远不被更新) 。
- 软更新：目标网络以 τ=0.005 平滑更新。
- 带折扣的经验回放：每条经验额外存 TD 折扣 γ^Δ t，目标为 y=r+(1-done) γ^Δ t Q'。这是因为两个智能体各自相邻决策之间隔着数步

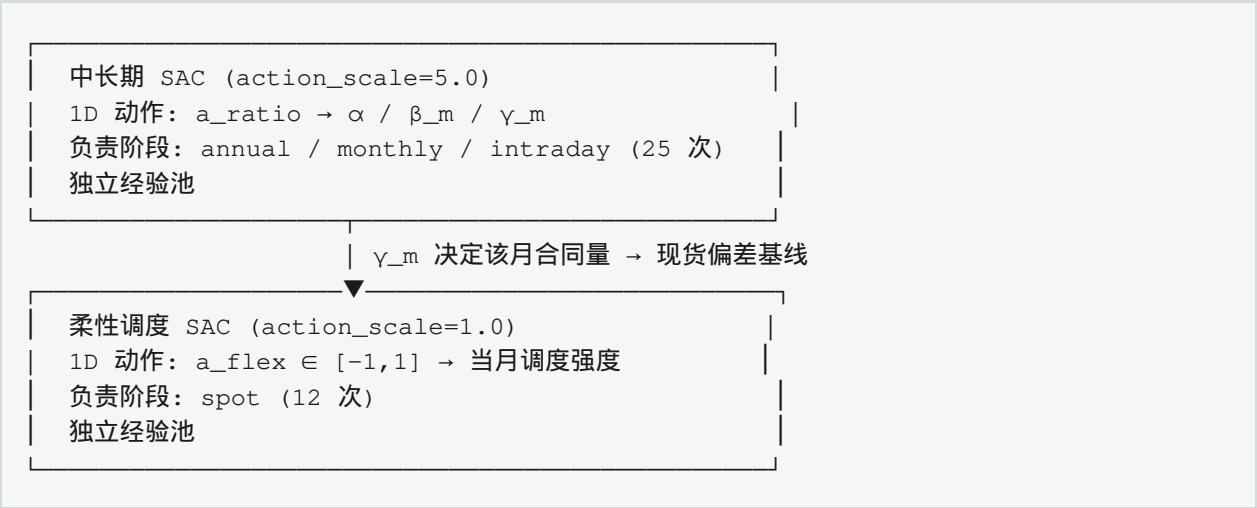
（见 4.3），用固定一步折扣会系统性错估跨期成本。

- 检查点指纹：`save()` 记录状态/动作维度与网络形状及 `action_scale / target_entropy / gamma / tau`，`load()` 发现不一致直接抛错，避免"用错配置继续训练"这类静默失真。

超参数见附录 B（Actor/Critic/温度学习率均为 3×10，折扣因子 0.99，批大小 256，经验池容量 10，初始温度 0.2）。

4.3 双智能体架构与决策时序

本文以 `MultiScaleCoordinator` 协调两个独立的 SAC 智能体：



"相互衔接"的体现：(1) 中长期智能体输出的 γ_m 直接决定柔性调度智能体面对的偏差基线 γ_m R_m 与现货阶段状态；(2) 两智能体共享同一环境状态但动作解耦、各用独立经验池，避免分布混合；
(3) 通过同月仓位约束 α≤β_m≤γ_m 保证跨尺度决策的时序一致性。
需要明确的是：柔性调度智能体只决定"多大程度择优调度"，不决定现货采购电量——
现货侧结算的是合同量与实际净需求之差，采购量由合同与真实需求共同决定，不由该智能体的动作直接给定。

按角色的决策时序（半 **MDP**）：每个智能体的 `next_state` 必须是本角色自己的下一次决策的观察，而不是环境的下一步观察；跨过的步数 Δ t 折算成 TD 折扣 γ^Δ t 写入回放。
回合末尾两个角色仍未闭合的挂起决策都按终止写入、不再 bootstrap（即使最后一步属于被冻结的角色，
否则该角色每回合会少一条经验）。验收：`experiments/test_agent_timing.py` 断言每回合
中长期/柔性分别新增 25/12 条经验，且若改用"环境的下一步"作为 `next_state`，
会精确在 11 + 11 个跨月转移上出现错误——说明错误已被定位并消除。

4.4 信用分配问题与未来暴露成本塑形

问题根源。 多智能体协同的难点在于信用分配。在电力交易中，中长期决策（α/β_m/γ_m）
决定了绝大部分购电成本，而柔性调度只影响现货偏差的边际成本。若两个智能体共享同一全局奖

励，
则柔性智能体动作对回报的边际影响被淹没在中长期决策带来的巨大成本噪声中；反之，若简单地把各阶段
成本作为各自即时奖励，中长期智能体会因"看不到"其 γ_m 决策所引发的未来现货成本而倾向于过度压低覆盖率，导致现货敞口失控。本节所有机制在修正后的会计口径下重新实现，其对成本的量化影响
需由重训结果给出，本报告不再引用作废口径上的数字。

解决机制。 本文在月内（**intraday**）决策步对中长期智能体的即时奖励施加未来暴露成本塑形：

> r_mid^intraday = -(c_intraday)/(R_m) - (1-γ_m) hat p_s

c_intraday 与该步合同成本均以该月参考电量 **R_m** 归一化，得到"元/MWh"量级的单位成本，
因此年度步（基准为 Q）不会以 12 倍的电能量级淹没后续决策。
hat p_s 取公开信息给出的现货水平预测——已交割月份日前价的滚动均值（首月退回公开年度合同价），
而不是当月实现价或生成器隐参，从而在不引入"完美预见"的前提下，让中长期智能体显式感知
"少锁仓 → 现货暴露增大 → 未来成本上升"的因果链，形成保持合理覆盖率的内在激励。

CVaR 风险项（η=0.95，λ 为风险厌恶系数）同样只施加于中长期智能体的月内决策步，
因为它决定暴露。

辅助机制（消融中被剔除）：(1) 现货奖励放大
r_spot=-(c_spot+penalty)/max(|Δ_m|, 0.05R_m)，除以实际暴露电量以放大弱信号；
(2) 三阶段交替训练。开发阶段的消融（作废口径）显示只有暴露成本塑形是承重部件；
该结论将在新口径下重做后写入第 5 章。

4.5 训练流程

每个价格场景独立训练一套智能体。四臂基准（`experiments/run_four_arm_benchmark.py`）中
SAC 臂使用冻结的训练预算：`--episodes 2000`，阶段划分固定为
P1 只训中长期（25%）→ P2 冻结中长期、只训柔性调度（25%）→ P3 联合（50%）；
分层臂 `sac_rule` 的下层是规则，其柔性 SAC 全程冻结、不写经验。

评估使用配对世界：`reset(options={"world": k})` 决定价格抽样种子，四臂在同一 seed 下
走同一批 k 世界、同一批设备任务，因此改进百分比是逐世界的配对差；不同训练 seed 对应不同世界组，
避免"在同一批世界上调参又在同一批世界上报告"。所有模型、动作序列、成本分解与
未通过会计校验的世界（failures 列表）都完整落盘，未通过校验的世界不进入汇总。

第 5 章 实验与结果分析

5.1 实验设置

- 环境：多时间尺度交易环境 v3.6（逐交割月台账 + 偏差结算 + 设备执行闭环 + 发布游标），13 维状态 / 2 维动作，Q=1000 MWh，12 个月 × 24 时段。
- 算法：SAC（超参数见附录 B）。中长期 SAC `action_scale=5.0`，柔性调度 SAC `action_scale=1.0`。
- 四个策略臂（同一环境、同一批配对世界、同一组设备任务）：
  1. `fixed_rule` 固定比例 + 保障调度：α=0.80, β_m=0.90, γ_m=0.95，强度恒为 0，不看价格。
  2. `rolling_rule` 滚动规则 + 预测调度：逐层比价决定覆盖率，按公开日前剖面的价差强度调度（不学习）。
  3. `sac_rule` 上层 **SAC** + 规则下层：只训中长期，柔性由 2 的规则给定（分层臂）。
  4. `dual_sac` 双 **SAC**：中长期 SAC + 柔性调度 SAC。
- 冻结的预算与随机性：训练 seed {42,142,242}，SAC 臂 2000 episodes，阶段划分 25%/25%/50%，
  评估使用 10 个配对世界（四臂逐同一批世界比较，改进按逐世界配对差计算并报告胜出次数）。
  冻结的是配置而非结果：同 seed 跨进程的 SAC 训练仍有波动，判读门槛见 5.4 节。
- 逐回合会计复核：每个世界在进入汇总前先通过电量守恒、合同量非负、成本可复算、设备按时完成任务等检查；未通过的写入 `failures` 列表并排除，不做静默平均。
- 评价指标：年总成本（元）、对基线臂的配对改进、逐世界胜出率、柔性节约、γ_m 与强度序列。

> 说明：`meta` 字段完整记录场景、臂、seed、episodes、评估世界数与模型路径，
> 任何一张表都可由 `results/four_arm_*.json` 复算。

5.2 会计与物理闭环验收（已通过）

最低门槛 6 项由 43 个验收用例逐条覆盖，全部通过：

验收项	关键断言	用例
无虚假退款	台账中非现货批次电量非负；跨月降覆盖率不冲销上月合同	`test_settlement_accounting.py`
电量守恒	Σ_m(合同 + 偏差) = 全年实际网侧净需求，残差 < 1e-6；中性调度时恰为 Q	`test_environment_accounting.py`
设备按时完成	EV 离场前 SOC 达标、工业日任务守恒、小时净负荷非负	`test_flexible_executor.py`
费用可手算	逐批台账（签约步/交割月/电量/单价/成本）之和 = 报告总成本	`test_environment_accounting.py`

观察不含未来实现值	篡改未来 11 月实现价 / 污染生成器隐参，篡改前决策的观察与奖励逐位不变	`test_information_boundary.py`
模型重载一致	重载后确定性动作逐位一致；`alpha_optim` 仍绑定 `log_alpha`；维度/超参不符即报错	`test_agent_timing.py`
决策时序	每回合中长期/柔性各新增 25/12 条经验；`next_state` 为本角色下一次决策观察	`test_agent_timing.py`、`test_four_arm_benchmark.py`

5.3 非学习基线的标定（已通过，实测数据）

DRL 的增益必须在够强且可复算的基线前接受检验。两个规则臂在同一批世界上的实测结果（10 配对世界 × 3 seed，会计校验失败世界数 0）：

场景	**`fixed_rule`** 成本	**`rolling_rule`** 成本	配对改进
A 年度低价后期上涨	314,643	314,214	+0.1%
B 年度高价后期下降	403,243	399,166	+1.0%
C 各阶段价格接近	351,437	351,705	–0.1%
D 现货高波动	344,677	344,145	+0.2%
E 月度低价现货极端风险	377,163	368,854	+2.2%

两点结论：其一，修正口径后的成本量级约 30–40 万元/年，与全年 1000 MWh 的实际采购规模相称（旧口径给出的约三倍量级数字已从本文删除）；
其二，仅靠公开的滚动比价与价差强度规则即可获得 0%~2.2% 的改进，
因此任何小于该量级的 **DRL "改进"都不构成证据**，必须与 `rolling_rule` 一起报告。

5.4 DRL 性能（重训进行中，本文暂不下结论）

`sac_rule` 与 `dual_sac` 两臂正在按 5.1 的冻结预算重训（5 场景 × 4 臂 × 3 seed）。
本报告在此处不填写任何降本百分比：在重训结果落盘并通过同一套会计复核之前，
写入数字就等于重复本次审计发现的问题。完成后由 `experiments/report_tables.py` 补齐四张表、`experiments/plot_four_arm_results.py` 出图，逐张回答：

1. 表 **5.4-1** 成本与配对改进：四臂 × 5 场景的年均成本（3 seed 均值 ± 种子间标准差），改进同时相对弱基线 `fixed_rule` 与强规则臂 `rolling_rule` 给出——只赢前者不构成证据；
2. 表 **5.4-2** 逐种子稳健性：逐 seed 的配对改进与"更省世界数 / 总世界数"，防止结论靠单个种子；

3. 表 **5.4-3** 成本分层占比：中长期三层与现货层的成本占比，用于核对 5.6 节的信用分配论证；
4. 表 **5.4-4** 决策口径与验收：逐 (场景, 臂) 合并后的通过世界数、γ_m 均值与强度幅值，验收未通过的组合单列并排除在汇总之外。

图侧另出 `four_arm_vs_strong_rule.png`（学习臂相对强规则臂的增量）、`four_arm_paired_worlds.png`（逐世界配对散点）与 `four_arm_gamma_profile.png`（γ_m 剖面）。
消融（去除暴露塑形 / 去除现货奖励归一化 / 不分阶段交替）在同一入口上加开关重跑。

> 判读门槛（来自一次意外重复运行的实测）：迭代 8.7.4 期间两条基准进程同时跑过同一批配置，
> 得到同种子、跨进程的评估成本差：`sac_rule` 0.09% / 0.21%，`dual_sac` 0.37% / 0.24%
> （两个规则臂在同样两次运行中逐位一致，说明波动只来自训练侧，不来自世界抽样）。
> 该对照取自事故时的运行日志（日志不随仓库发布），因此这里把它当作保守的经验门槛使用。
> 也就是说冻结 **seed** 只固定配置，不固定结果。因此本节按下述门槛判读：
> 改进幅度需明显大于 0.4%，且在 3 个种子 × 10 个配对世界上方向一致，才称为改进；
> 低于该量级的差值写作"与运行间噪声同量级"，不进入结论。
> 作为对照，5.3 节规则臂相对弱基线的改进在 A/C/D 三个场景只有 ≤0.15%，本身已落在噪声带内。

5.5 开发阶段结果的作废说明

迭代 7 及之前给出的全部成本绝对值与改进百分比已作废并从本文删除（分层架构臂与双 DRL 臂当时报告的两位数降本均属此类）。作废理由是计量缺陷而非策略退化：旧版结算对同一度电重复计量约 3.25 倍，导致成本被系统性夸大，且策略只要改变"合同/现货"的记账比例就能在错误口径下"省下"被重复计费的那部分电量——这是计量缺陷的放大器，不是策略收益。
在同一缺陷下，消融实验出现过"移除塑形后成本飙到数百万元"这类超出任何合理购电成本量级的极端值，"完整方案 vs 简化方案"之间的差值同样不具备解释力。这些结论连同其图表已从本文移除，如需追溯原始数值可查看 git 历史（提交 `f2b4f7c` 及之前）。

修正口径后，基线之间的真实差距为 0%~2.2% 量级（见 5.3 节），与旧口径的两位数百分比相差一个数量级，
这正是 5.8 节第 1 条讨论的实证依据。

5.6 信用分配有效性的证据

奖励量级比是一个随归一化方式而变的诊断量，旧口径给出的数值已随作废数据删除；
本文改用可复现的实测：在 v3.6 中，奖励按各步决策的
电量基准归一化（年度步 Q，月度/月内/现货步 R_m），现货步另除以实际暴露电量并设下限 0.05R_m。
实测（`experiments/measure_reward_scale.py`，
5 场景 × 2 个规则臂、世界 0、确定性策略，逐回合单位奖励绝对值之比）

给出 |r_spot|/|r_mid| = 1.5sim10.2，均值 6.9——
即两个角色的信号已在同一量级（未归一化时，柔性步的量级比合同步低一到两个数量级）。
该指标只说明"学习信号量级可比、柔性步不被淹没"，不等于性能改进；性能结论见 5.4 节的待补内容。

同一脚本还逐回合记录了成本的分层占比，用来标定信用分配困难的来源量级：在修正后的会计下，中长期三层（年度 + 月度 + 月内）占全年总成本的 92\%sim99\%，均值 94.7%，现货层只占 0.9\%sim8\%。也就是说"柔性/现货侧决策天然只影响一小部分成本"这一判断在新口径下依然成立，它正是必须做暴露成本塑形与按电量基准归一的原因（旧口径给出的 95:5 说法数字来源不可靠，已改为此实测值）。

5.7 风险度量（CVaR）与策略结构分析

在奖励中对中长期智能体的月内决策步引入 CVaR 风险项（置信水平 η=0.95，风险厌恶系数 λ=0.1），
惩罚现货月度成本的尾部。开发阶段的 λ 敏感性分析（λ∈{0,0.05,0.1,0.2,0.5}）
显示 λ 对仓位结构的影响呈非单调特征，存在临界点——过小则风险约束形同虚设，
过大则过度保守推高成本。该分析的绝对数值随口径一并作废，其定性形态将在重训后复核。

月度比例动态：旧口径下观察到的"年末 γ 骤降（收官效应）"在新口径下有明确解释——
跨月覆盖率降低是对不同交割月分别签约、不构成退款，因此年末少锁仓是合法策略；
但旧报告把它当作"智能体学到的收益机制"来叙述，其收益部分来自重复计量，故该叙述作废。
新口径下的 γ_m 序列已由四臂基准逐世界记录，重训完成后在此给出曲线。

5.8 讨论

1. 为什么必须先修会计再谈算法：结算重复计量时，"改比例"本身就能在账面上省钱，
   任何策略比较都被这个假信号支配（旧口径的两位数改进 vs 新基线 0~2.2% 的落差就是证据）。
   修正后成本可由台账逐批复算，策略差异才第一次具有经济含义。
2. 强非学习基线的必要性：滚动规则只用公开信息、零训练成本即可获得最高 2.2% 的改进。
   若仍以"固定比例 + 无柔性"为唯一对照，DRL 很容易获得虚高的结论；
   因此四臂设计把 `rolling_rule` 设为必须同时报告的对照。
3. 信用分配仍是本问题的核心难点：并行双智能体与共享全局奖励两种朴素方案都失败过，
   根因是中长期与柔性两类决策的成本量级悬殊。暴露成本塑形 + 单位电量归一化 + 按角色决策时序
   是本文的方法论主张，其定量贡献需由重训后的消融给出。
4. 物理可行性优先于经济性：EV 离场 SOC、工业日任务守恒等约束写在执行层而非奖励里，
   因此"设备按时完成任务"是构造性保证。这也意味着柔性收益天然受限——
   往返损耗 12.4% 加上过购折卖 20%，使放电只有在日内波幅超过约 46% 时才划算，
   这解释了为什么规则臂在低波动场景 C 中只能做到 ±0.1%。

第 6 章 结论与展望

6.1 主要结论

本文围绕"基于深度强化学习的多时间尺度电力交易策略"展开研究，主要工作与结论如下：

1. 构建了年度/月度/月内/现货四级市场的多时间尺度交易环境，按交割月记账（参考交付电量 R_m、合同台账、逐时段偏差结算），并集成 EV 集群与工业可转移负荷的物理执行模型（SOC 时序积分、日任务守恒）；全年合同电量恒等于 Q，成本可由台账逐批手算复核。
2. 提出双 **DRL** 智能体协同框架（中长期 SAC + 柔性调度 SAC），通过动作解耦、独立经验池、按角色衔接的半 MDP 决策时序与同月仓位约束实现"相互衔接"，满足任务书要求；明确柔性调度智能体只决定调度强度、不决定现货采购电量。
3. 针对多智能体信用分配难题，提出未来暴露成本塑形机制（配合单位电量奖励归一化与跨步折扣 γ^Δ t），使两个角色的学习信号处于同一量级。
4. 建立可复算的验证体系与公平实验框架：43 个验收用例覆盖"无虚假退款、电量守恒、设备按时完成、费用可手算、观察不含未来实现值、模型重载一致"，四臂配对世界基准把"滚动规则 + 预测调度"这一非学习强基线纳入必须同时报告的对照。
5. 关于经济性：本文实测成立的结果是 5.2/5.3 节的验收与基线标定（滚动规则相对固定比例 +0.1%~+2.2%，场景依赖），以及 5.4 节写明的判读门槛（改进需明显大于 0.4% 且跨 3 个种子、10 个配对世界方向一致）。
   双 **DRL** 相对基线的降本比例尚无有效结论——迭代 7 报告的降本百分比测量于同一度电重复计量约
   3.25 倍的旧口径之上，已整体作废并从本文删除；正式结论以修正口径重训后的 `results/four_arm_benchmark.json` 为准。
   CVaR 敏感性与"收官效应"等结构分析的定性形态仍值得检验，但其数值同样作废待重做。

6.2 局限与展望

1. 数据为合成场景：价格数据由预定义参数叠加随机噪声生成，虽处于合理区间，但仍需在真实市场数据上验证泛化性。
2. 单用户视角：当前模型未考虑多主体博弈对市场价格的反作用，未来可引入多智能体博弈或市场出清机制。
3. 柔性模型简化：EV 到达/离开与工业转移采用统计化建模，可进一步引入更精细的用户行为模型。
4. 算法可拓展性：可将 SAC 替换为 TD3、IQL 等，或引入分层/课程学习进一步改善长时序信用分配；亦可探索离线强化学习以利用历史交易数据。
5. 会计口径是最大的不确定性来源：本项目最重要的教训是——结算缺陷不会让结果"偏大偏小"，而是会让错误的策略看起来更优。

后续工作应把"电量守恒 + 台账可手算"作为任何实验前的前置门禁，并对过购折价、辅助服务补偿等
目前简化处理的经济学假设做敏感性分析。

6. **"配置冻结"不等于"结果可复现"**：同一种子在两个独立进程里训出的策略，评估成本相差 0.09%~0.37%（见 5.4 节门槛）。报告任何小于该量级的差值时都应同时给出运行间噪声，否则容易把训练随机性叙述成策略收益——这正是本文撤回旧结论时吃过亏的地方。
7. **性能结论的时间性**：本报告的实验章节在提交时点仍有一份重训在进行中；若最终数字与本文的机制叙述冲突，应以数字为准修订方法主张，而不是反过来调整评估口径。

参考文献

[1] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]. ICML, 2018: 1861-1870.

[2] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[C]. ICLR, 2016.

[3] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[J]. arXiv:1707.06347, 2017.

[4] Rockafellar R T, Uryasev S. Optimization of conditional value-at-risk[J]. Journal of Risk, 2000, 2(3): 21-41.

[5] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[6] Vamplew P, et al. Safety-gym: A reinforcement learning environment for the study of safety-critical situations[C]. 2022.

[7] 国家能源局. 电力现货市场基本规则（试行）, 2023.

[8] 中电联. 全国电力工业统计, 2024.

[9] Hernandez L, et al. Survey on electric vehicle behaviour modelling for demand-side management[J]. Renewable and Sustainable Energy Reviews, 2014.

[10] Rabault B, et al. Fast reinforcement learning for optimized portfolio asset management[C]. NeurIPS, 2022.

> 注：以上为方法学相关代表性文献，正式提交前请依据学校格式规范补全并核对。

附录 A 项目代码结构

文件	用途	负责组

src/market/environment.py	多时间尺度交易 Gym 环境（v3.6：偏差结算 + 设备执行闭环 + 发布游标）	第一组
src/market/market_models.py	5 种价格场景生成器（按配对世界抽样）	第一组
src/market/settlement.py	逐交割月结算引擎、合同台账、偏差结算、CVaR	第一组
src/load/ev_model.py	EV 集群充放电参数与包络	第二组
src/load/industrial_load.py	工业可转移负荷参数与包络	第二组
src/load/flexible_executor.py	执行层：推进 SOC / 日任务守恒，输出真实网侧净负荷	第二组
src/load/load_scenarios.py	5 种负荷场景组合	第二组
src/agent/sac_agent.py	SAC（Actor/Critic/ReplayBuffer，带 γ^Δ t 折扣与检查点指纹）	第三组
src/agent/multi_agent.py	双 SAC 协调器（独立经验池、按角色决策时序、冻结标志）	第三组
src/agent/rule_policies.py	两个非学习基线臂（固定比例 / 滚动规则 + 预测调度）	第三组
src/utils/config.py、logger.py	全局参数、日志	公共
experiments/run_four_arm_benchmark.py	正式实验入口：四臂配对世界基准 + 逐回合会计复核	第三组
experiments/run_all_scenarios.sh	逐场景长跑驱动（可中断续跑）+ 结束时自动合并分片	公共

`experiments/merge_four_arm_parts.py`	合并逐场景分片、校验冻结预算一致性与缺失组合	第三组
`experiments/plot_four_arm_results.py`	结果出图：配对改进、学习臂 vs 规则臂、逐世界配对、成本分层、γ_m 剖面	第三组
`experiments/report_tables.py`	由合并 JSON 直接渲染 5.4 节四张表（含验收未通过组合的隔离提示）	第三组
`experiments/measure_reward_scale.py`	实测单位奖励量级比与成本分层占比（5.6 节数据来源）	第三组
`experiments/test_settlement_accounting.py` 等 7 个 `test_*.py`	43 个验收用例（最低门槛 6 项）	公共
`experiments/md_to_pdf.py`	报告排版导出	公共

> 迭代 1–7 的训练与绘图脚本（`train*.py`、`run_ablation.py`、`plot_*.py`、`generate_*.py`、`analyze_*.py`、`gap_analysis.py`）以及旧规则调度器 `src/load/flexible_dispatcher.py`，
> 随作废口径一并从仓库删除；训练与评价统一走 `run_four_arm_benchmark.py`。
> 消融（6.2 节待补）改为在该入口上加开关实现。

附录 B 关键超参数

类别	参数	取值
市场	总需求 Q / 参考交付电量 R_m	1000 MWh / 均匀 Q/12
市场	覆盖率上限 α / β_m / γ_m	0.90 / 0.95 / 1.00
市场	固定比例基准 α/β_m/γ_m	0.80 / 0.90 / 0.95
市场	暴露参考上限（放电空间折算）	0.30
结算	富余回售折价 d	0.20（唯一显式不对称参数）
市场	决策周期	12 月 × 24 时段，每月 30 天
EV	数量 / 容量 / 充放功率	50 辆 / 60 kWh / 7 kW、3 kW
EV	SOC 区间 / 目标 / 初始	[0.2, 0.9] / 0.8 / 0.3

EV	充电 / 放电效率	0.90 / 0.88（往返损耗 12.4%）
工业	总功率 / 可转移比例 / 窗口	200 kW / 0.3 / 4 h
工业	转移惩罚 / 最低生产负荷率	50 元/MWh / 0.6
规则臂	V2G 门槛 = 往返损耗 + 回售折价	≈ 0.4626
规则臂	hedge_gain / dispatch_gain / annual_anchor	1.5 / 1.0 / 0.80
SAC	隐藏维 / 学习率	256 / 3e-4（actor、critic、温度）
SAC	折扣因子 / 软更新	0.99 / 0.005
SAC	批大小 / 经验池 / 初始温度	256 / 1,000,000 / 0.2
SAC	action_scale（中长期 / 柔性调度）	5.0 / 1.0
奖励	现货步暴露下限 MIN_SPOT_EXPOSURE	0.05（× R_m）
训练	episodes / 阶段划分	2000 / 25% + 25% + 50%
风险	λ / η	0.1 / 0.95
实验	训练 seed / 配对评估世界数	42, 142, 242 / 10

附录 C 复现说明

```
# 环境：conda env power_trading, Python 3.11, torch(CPU)；Windows 需
PYTHONIOENCODING=utf-8
export PYTHONIOENCODING=utf-8

# 1) 验收门禁（6 项最低门槛，43 用例）
for f in test_settlement_accounting test_environment_accounting
test_flexible_executor \
         test_information_boundary test_agent_timing test_four_arm_benchmark
test_modules; do
    python experiments/$f.py
done

# 2) 正式四臂基准（5 场景 × 4 臂 × 3 种子 × 2000 回合）
bash experiments/run_all_scenarios.sh
#    该驱动逐场景落盘（中断只丢一个场景），结束时自动调用
#    experiments/merge_four_arm_parts.py 合并分片并重算配对改进
#    （合并前会检查各分片的冻结预算一致性与缺失的 场景/种子/臂 组合）

# 3) 只看非学习基线（不训练，秒级）
python experiments/run_four_arm_benchmark.py --no-train
# 4) 5.6 节的两个实测（单位奖励量级比、成本分层占比；秒级）
python experiments/measure_reward_scale.py
```

```
# 5) 5.4 节的图表与表格（只读合并后的 JSON，秒级）
python experiments/plot_four_arm_results.py --in results/
four_arm_benchmark.json
python experiments/report_tables.py         --in results/
four_arm_benchmark.json
```

迭代 1–7 的训练与绘图脚本（`train*.py`、`run_ablation.py`、`plot_*.py` 等）连同其作废输出已从仓库删除——旧结果是如何产生的，可由 git 历史（提交 `f2b4f7c` 及之前）中的脚本与文档复现，但那些数字不得作为结论引用。

报告版本：迭代 *8.7.4*（修正结算口径 + 设备执行闭环 + 信息边界 + 四臂配对基准 + 结果判读门槛；迭代 *7* 及之前的成本与改进百分比已作废并从本文删除，*DRL* 性能结论以重训结果为准）